시계열자료분석팀

5팀

김나현 강철석 이승아 김재원 이신영

CONTENTS

- 1. 모형의 식별
 - 2. 선형 과정
- 3. 정상 시계열 모형
- 4. 비정상 시계열 모형
- 5. 이분산 시계열 모형

1

모형의 식별

시계열 모형의 필요성

대각요소: 본인과의 오차항
$$Y_t$$
의 공분산 행렬
$$\Gamma = \begin{pmatrix} Cov(Y_1,Y_1) & Cov(Y_1,Y_2) & \cdots & Cov(Y_1,Y_n) \\ \vdots & & & \vdots \\ Cov(Y_n,Y_1) & Cov(Y_n,Y_2) & \cdots & Cov(Y_n,Y_n) \end{pmatrix}$$

$$= \begin{pmatrix} \gamma(0) & \gamma(1) & \cdots & \gamma(n-1) \\ \vdots & & & \vdots \\ \gamma(n-1) & \gamma(n-2) & \cdots & \gamma(0) \end{pmatrix}$$

- Y_t가 백색잡음(WN)일 경우 - -

행렬 내 대각요소를 제외한 요소의 값은 모두 0이 되어 분산만 추정

시계열 모형의 필요성

대각요소: 본인과의 오차항
$$Y_t$$
의 공분산 행렬
 $\Gamma = \begin{pmatrix} Cov(Y_1,Y_1) & Cov(Y_1,Y_2) & \cdots & Cov(Y_1,Y_n) \\ \vdots & & \vdots & & \vdots \\ Cov(Y_n,Y_1) & Cov(Y_n,Y_2) & \cdots & Cov(Y_n,Y_n) \end{pmatrix}$

$$= \begin{pmatrix} \gamma(0) & \gamma(1) & \cdots & \gamma(n-1) \\ \vdots & & \vdots & & \vdots \\ \gamma(n-1) & \gamma(n-2) & \cdots & \gamma(0) \\ & & & & \end{pmatrix}$$
하삼각요소

- Y_t가 백색잡음(WN)이 아닐 경우

시계열 모형을 활용하여 하삼각요소를 모두 추정해야 함

모형의 식별

시계열 모형의 필요성



회귀/평활/차분 등의 정상화 방법을 통해 비정상 시계열을 정상 시계열로 변환한 후에도 남아있는 오차가 IID 또는 WN를 만족하지 않는 상황




시계열 모형을 활용한 추정 진행



1 모형의 식별

시계열 모형의 필요성





자기상관함수(ACF)

자기상관함수 (Autocorrelation Function)

시차가 h인 시계열 간의 상관관계를 의미하며, 정상성 만족 시 시차에만 의존함



ACF(p)의 특징

i.
$$\rho(0) = 1 (: \gamma(0) = var(X_t))$$


ii.
$$\rho(-h) = \rho(h)$$

iii.
$$|\gamma(h)| \le \gamma(0)$$
 for all $h \in Z \to |\rho(h)| \le 1$

부분자기상관함수(PACF)

Ex.

[X = 아이스크림 판매량, Y = 범죄발생건수, Z = 인구 수] 변수 설정



X와 Y의 **상관관계** 증가

모형의 식별

▮ 부분자기상관함수(PACF)

Ex.

[X = 아이스크림 판매량, Y = 범죄발생건수, Z = 인구 수] 변수 설정



이는 두 변수 모두 **Z의 영향**을 받아 발생한 결과이므로 Z의 영향을 제거한 순수한 X와 Y의 상관계수를 구해야 함

Z 증가



X, Y 증가

부분상관계수 사용 X와 Y의 상관관계 증가

부분자기상관함수(PACF)

부분상관계수

Z의 영향을 제거한 X와 Y의 부분상관계수

$$\rho_{XY,Z} = \frac{E([X - E(X|Z)] * [Y - E(Y|Z)])}{\sqrt{E[X - E(X|Z)]}^2 * \sqrt{E[Y - E(Y|Z)]^2}} = \rho(X^*, Y^*)$$

E(X|Z): X가 Z에 의해 설명되는 부분

E(Y|Z): Y가 Z에 의해 설명되는 부분

 X^* : X에서 Z의 영향력을 제거하고 남은 부분

 Y^* : Y에서 Z의 영향력을 제거하고 남은 부분

부분자기상관함수(PACF)

부분자기상관계수

자기 자신과의 부분상관계수

 X_{t} 와 X_{t+k} 의 상관관계를 구할 때, 그 둘 사이에 존재하는 $\{X_{t+1}, X_{t+2}, \cdots, X_{t+k-1}\}$ 의 영향을 제외하고 구한 상관계수



$PACF(\alpha)$

i.
$$\alpha(0) = Corr(X_1, X_1) = 1$$

ii.
$$\alpha(1) = Corr(X_1, X_2) = \rho(1)$$

iii.
$$\alpha(k) = Corr(X_{k+1} - P_k^* X_{k+1}, X_1 - P_k^* X_1), \quad k \ge 2$$

각각 X_{k+1} , X_1 의 오차항을 최소화하는 추정치

2

선형 과정

선형 과정

선형 과정

$$X_t = \sum_{j=-\infty}^{\infty} \psi_j Z_{t-j}$$

 $\{Z_t\} \sim WN(0,\sigma^2)$ 들의 선형결합




이때, 선형결합의 계수는

 $\sum_{i} |\psi_{i}| < \infty$ (absolutely summable) 조건 만족해야 함

선형 과정



선형 과정 왜 시계열을 선형과정으로 표현할까?



3

정상 시계열 모형

3 정상 시계열 모형

AR(Auto Regressive Model): 자기회귀모형

자기회귀모형

현 시점의 관측값을 과거 시점의 관측값과 현 시점의 오차의 함수 형태로 나타내는 모형


관측값을 자기 자신의 과거에 회귀시킨다는 의미에서 **자기회귀**라는 표현을 사용


자기회귀모형

$$AR(1): \phi_1 X_{t-1} + Z_t$$

$$AR(p): X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + Z_t$$

$$where Z_t \sim WN(0, \sigma^2)$$





AR 모형의 특성방정식

AR(p) 모형

$$AR(p)$$
: $X_t = \phi X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + Z_t$

후향연산자를 활용하여 표현

$$X_t = \phi_1 B X_t + \phi_2 B^2 X_t + \dots + \phi_p B^p X_t + Z_t$$

Z_t 에 대해 정리

$$Z_t = (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) X_t$$

AR 모형의 특성방정식



$$\left(1 - \phi_1 B - \phi_2 B^2 + \cdots - \phi_p B^p\right) = \phi(B)$$


로 표현하고 이때 $\phi(B)$ 를 특성 방정식이라고 부름. AR(p): $X_t = \Phi_1 X_{t-1} + \Phi_2 X_{t-2} + \cdots + \Phi_n X_{t-n} + Z_t$

후향연산자를 활용하여 표현

특정방정식을 사용하여 AR 모형을 다음과 같이 표현할 수 있음

$$Z_t = \phi(B)X_t$$

$$Z_t = \left(1 - \Phi_1 B - \Phi_2 B^2 - \dots - \Phi_p B^p\right) X_t$$




시계열의 확률적 특성이 시점에 의존하지 않아야 하는 특성

t 시점의 관측값이 과거시점의 오차항으로 설명될 수 있다는 특성

$$\psi_j = 0$$
, $\forall j < 0 \leftrightarrow X_t = \sum_{j=0}^{\infty} \psi_j Z_{t-j}$



두 가지 조건을 반드시 만족해야 함



두 가지 조건을 반드시 만족해야 함

인과성 | AR(1)

$$\begin{split} X_t &= \phi_1 X_{t-1} + Z_t \\ &= \phi_1 (\phi_1 X_{t-2} + Z_{t-1}) + Z_t = \phi_1^2 X_{t-2} + \phi_1 Z_{t-1} + Z_t \\ &= \phi_1^2 (\phi_1 X_{t-3} + Z_{t-2}) + \phi_1 Z_{t-1} + Z_t \\ &= \phi_1^3 X_{t-3} + \phi_1^2 Z_{t-2} + \phi_1 Z_{t-1} + Z_t \\ &\vdots \\ &= \phi_1^{M+1} X_{t-M-1} + \sum_{j=0}^M \phi_1^j Z_{t-j} \end{split}$$

 $\phi_1^{M+1}X_{t-m-1}$ 부분이 사라져야 인과성 만족

인과성 | AR(1)

For
$$X_t = \phi_1^{M+1} X_{t-m-1} + \sum_{j=0}^{M} \phi_1^j Z_{t-j}$$
,

If $M \to \infty$, then $\phi_1^{M+1} X_{t-m-1} \to 0$



 $|\phi| < 1$ 일 때 오차항의 선형결합 Z_t 만 남아 인과성 만족

ACF | AR(1)

AR(1) 식 양변에 X_{t-h} 곱

$$X_{t} = \phi_{1}X_{t-1} + Z_{t}$$

$$X_{t}X_{t-h} = \phi_{1}X_{t-1}X_{t-h} + Z_{t}X_{t-h}$$

기댓값 취해 ACF 식 유도

편의상 $E(X_t) = 0$ 가정

$$\gamma(h) = \phi_1 \gamma(h-1) + Cov(Z_t, X_{t-h}) = \phi_1 \gamma(h-1)$$

$$(\because Cov(Z_t, X_{t-h}) = Cov(Z_t, \phi_1^{M+1} X_{t-M-1} + \sum_{j=0}^{M} \phi_1^j Z_{t-h-j} = 0)$$

$$\gamma(h) = \phi_1(\phi_1\gamma(h-2)) = \cdots = \phi_1^h\gamma(0)$$

$$\frac{\gamma(h)}{\gamma(0)} = \phi_1^h = \rho(h)$$

ACF | AR(1)

$$X_{t} = \phi_{1} \qquad 1 + Z_{t}$$

$$X_{t}X_{t-h} = \phi_{1} \qquad X \times X = 0$$

$$\frac{\gamma(h)}{\gamma(0)} = \phi_{1}^{h} = \rho(h) \stackrel{\leftarrow}{\vdash} h$$
가 커짐에 따라 지수적 감소
$$\gamma(h) = \phi_{1}\gamma(h-1) + Cov(Z_{t}, X_{t-h}) = \phi_{1}\gamma(h-1)$$

$$(\because Cov(Z_{t}, X_{t-h}) = Cov(Z_{t}, \phi_{1}^{M+1}X_{t-M-1} + \sum_{j=0}^{M} \phi_{1}^{j}Z_{t-h-j} = 0)$$

$$\gamma(h) = \phi_{1}(\phi_{1}\gamma(h-2)) = \cdots = \phi_{1}^{h}\gamma(0)$$

$$\frac{\gamma(h)}{\gamma(0)} = \phi_{1}^{h} = \rho(h) \qquad \text{편의상 } E(X_{t}) = 0$$
 가정

PACF | AR(P)

AR(p) 식 정리

$$\hat{X}_{k+1} = \phi_1 X_k + \phi_2 X_{k-1A} + \dots + \phi_p X_{k+1-p}$$

= $\phi_1 X_k + \phi_2 X_{k-1A} + \dots + \phi_p X_{k+1-p} + 0 X_{k-p} + \dots + 0 X_1$


PACF의 성질 이용해 AR 모형의 PACF 정리

$$\alpha(0)\coloneqq 1$$
 , $\alpha(p)=\phi_p$, $\alpha(k)=0$ if $k>p$



AR 모델의 PACF는 p 시차 전까지만 존재하며, p이후로는 모두 0이 되는 것을 확인 (절단)

AR 모델의 ACF, PACF plot



위 그림에서는 p=1

정상 시계열 모형

MA(Moving Average Model): 이동평균모형

이동평균모형

관측값을 과거시점의 오차항만을 이용해 설명하는 모형

$$MA(1): X_t = Z_t + \theta_1 Z_{t-1}$$


$$MA(q): X_t = Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \dots + \theta_q Z_{t-q}$$

$$where Z_t \sim WN(0, \sigma^2)$$

q는 몇 시점 전까지의 오차항의 선형결합으로 표현했는지를 의미함

이동평균모형

관측값을 과거시점의 오차항만을 이용해 설명하는 모형



오차항의 증가로 더 요동치는 형태를 가짐

MA 모형의 특성방정식

MA(q) 모형

$$MA(q): X_t = Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \dots + \theta_q Z_{t-q}$$

후향연산자를 활용하여 표현

$$X_t = Z_t + \theta_1 B Z_t + \theta_2 B^2 Z_t + \dots + \theta_q B^q Z_t$$
$$= (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q) Z_t$$
$$= \theta(B) Z_t$$

MA 모형의 특성방정식

$$MA(q) 모형$$


$$-MA(q) \cdot X_t = Z_t + \theta_1 Z_t \qquad \theta_2 Z_{t-2} \pm \cdots \pm \theta_q Z_{t-q} - \theta_1 Z_{t-q} - \theta_2 Z_{t-2} + \cdots + \theta_q B^q) = \theta(B)$$

$$\theta(B) \succeq MA(q) = \theta(B)$$

$$X_t = Z_t + \theta_1 B Z_t + \theta_2 B^2 Z_t + \cdots + \theta_q B^q Z_t$$

$$= (1 + \theta_1 B + \theta_2 B^2 + \cdots + \theta_q B^q) Z_t$$

$$= \theta(B) Z_t$$



9

세 가지 조건들을 반드시 만족해야 함

가역성(Invertibility)

t시점의 오차항을 과거 시점의 관측값으로 표현할 수 있는 성질

 $\sum_{j=0}^{\infty} \left| \pi_j \right| < \infty$ 인 $\left\{ \pi_j \right\}$ 가 존재할 때,

 $Z_t = \sum_{j=0}^{\infty} \pi_j X_{t-j}$ for all t 를 만족하면

확률 과정이 가역적(invertible)이라고 표현

3 정상 시계열 모형

MA(Moving Average Model): 이동평균모형

가역성(Invertibility)

t시점의 오차항을 과거 시점의 관측값으로 표현할 수 있는 성질



Z 즉, 가역성은 White Noise Z_t 를 X_t 로 표현할 수 있는 지에 대한 여부를 따지는 조건!

가역성 | MA(1)

MA(1) 식 정리


$$X_t = Z_t + \theta Z_{t-1} = (1 + \theta B)Z_t$$

 $(1 + \theta B)^{-1}X_t = Z_t$

 $(1 + \theta B)^{-1}$ 를 무한 등비급수의 합으로 표현

$$(1 + \theta B)^{-1} = \frac{1}{1 - (-\theta B)} = 1 - \theta B + \theta B^2 - (\theta B)^3 + \cdots p$$

가역성 | MA(1)



ACF | MA(1)

MA(1) 식 양변에 X_{t-h} 곱하기

$$X_{t-h}X_t = X_{t-h}(Z_t + \theta_1 Z_{t-1}) = X_{t-h}Z_t + \theta_1 X_{t-h}Z_{t-1}$$

기댓값 취해 ACF식 구하기

$$\gamma(h) = Cov(X_{t-h}, Z_t + \theta_1 Z_{t-1})$$

$$= Cov(Z_{t-h} + \theta_1 Z_{t-h-1}, Z_t + \theta_1 Z_{t-1})$$

편의상 $E(X_t) = 0$ 가정

MA(Moving Average Model): 이동평균모형

ACF | MA(1)

h 값에 따른 $\gamma(h)$ 도출




$$h = 0$$

$$\gamma(0) = Cov(Z_t, +\theta_1 Z_{t-1}, Z_t + \theta_1 Z_{t-1}) = \sigma^2 + \theta_1^2 \sigma^2 = (1 + \theta_1^2)\sigma^2$$



$$h=1$$

$$\gamma(1) = Cov(Z_{t-1}, +\theta_1 Z_{t-2}, Z_t + \theta_1 Z_{t-1}) = \theta_1 \sigma^2$$



$$\gamma(h) = Cov(Z_{t-h}, +\theta_1 Z_{t-h-1}, Z_t + \theta_1 Z_{t-1}) = 0$$

ACF | MA(1)

$$\rho(k) = \frac{\gamma_k}{\gamma_0} = \begin{cases} \frac{\theta}{1 + \theta^2}, k = 1\\ 0, k \ge 2 \end{cases}$$



MA(q)모형의 ACF는 시차 q 이후 절단됨

PACF | MA(q)

$$\phi_{kk} = \frac{-(-\theta)^k}{(1+\theta^2+\dots+\theta^{2k})}, \qquad k \ge 1$$

MA 모형이 $|\theta|$ < 1일 때 성립하므로,

If $k \to \infty$, then $\phi_{kk} \to 0$


PACF | MA(q)

$$\phi_{kk} = \frac{-(-\theta)^k}{(1+\theta^2+\dots+\theta^{2k})}, \qquad k \ge 1$$




MA모형의 PACF는 지수적으로 감소함

MA 모델의 ACF, PACF plot



MA(Moving Average Mode)이동평균모형

MA 모델의 ACF, PACF plot



ACF의 로수의 절약을 위해 ARMA모형 사용은 지수적 감소

ARMA

ARMA(Auto Regressive Moving Average Model)

$$X_t - \phi_1 X_{t-1} - \dots - \phi_p X_{t-p} = Z_t + \theta_1 Z_{t-1} + \dots + \theta_q Z_{t-q}$$

'

좌변에는 AR 모형, 우변에는 MA 모형을 표현해 두 모델들의 성질을 포괄하는 모델

ARMA | 특성방정식

ARMA(p,q) 모형

$$X_t - \phi_1 X_{t-1} - \phi_2 X_{t-2} - \cdots - \phi_p X_{t-p} = Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \cdots + \theta_q Z_{t-q}$$

후향연산자를 활용하여 표현

$$X_t - \phi_1 B X_t - \phi_2 B^2 X_t - \cdots - \phi_p B^p X_t = Z_t + \theta_1 B Z_t + \theta_2 B^2 Z_t + \cdots + \theta_q B^q Z_t$$

특성방정식으로 표현

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) X_t = (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q) Z_t$$


AR 모형 특성방정식 $\phi(B)X_t = \theta(B)Z_t$ MA 모형 특성방정식

ARMA | 조건



주어진 파라미터 조합에 대해 단 하나의 모형이 대응되는 특성

ARMA | 조건




$$(1 - \phi B)X_t = (1 + \theta B)Z_t \Leftrightarrow \phi = -\theta$$

만족하는 ARMA(1,1) 모형


백색잡음(WN)



ARMA | ACF와 PACF



ARMA | ACF와 PACF



정상 시계열 모형의 적합 절차 | 모형 식별



먼저 **사용할 모형**과 해당 **모형의 차수**를 결정해야 함 AR(p)와 MA(q)의 경우, ACF 또는 PACF 그래프의 절단을 통해 차수를 결정할 수 있었으나, ARMA **모형은 해당하지 않음**



Information Criteria 사용 (AIC, AICC, BIC)

정상 시계열 모형의 적합 절차 | 모형 식별

Information Criteria(IC)

Information Criteria = {Goodness of fit + Model Complexity}

모형의 복잡도를 고려하기에 모형 식별을 위한 적절한 지표로 판단 가능여러 모형 중, 가장 작은 Information Criteria 값을 가지는 모형 선택

정상 시계열 모형의 적합 절차 | 모형 식별



AIC (Akalike Information Criteria)

대표본의 경우

$$-2\ln L_n(\hat{\theta}) + 2(p+q+1)$$

SSE에 대한 approximation



AICC (AIC biased corrected)

소표본의 경우

$$-2\ln L_n(\hat{\theta}) + \frac{2(p+q+1)n}{n-(p+q+1)+1}$$



BIC (Bayesian Information Criterion)

파라미터 개수 많을 경우

$$-2\ln L_n(\hat{\theta}) + (p+q+1)\ln n$$

정상 시계열 모형의 적합 절차 | 모수 추정



최대가능도추정법(MLE)

결합 확률 밀도함수인 모수의 가능도 함수를 최대화하는 모수의 추정량을 구하는 방법 최소제곱법(LSE)

오차의 제곱합이 가장 작아지도록 하는 모수의 추정량을 구하는 방법 적률추정법 (MME/MoM)

모집단의 적률을 표본의 적률로 대체한 후, 방정식을 풀어 모수의 추정량을 구하는 방법

정상 시계열 모형의 적합 절차 | 모수 추정



정상 시계열 모형의 적합 절차 | 모형 진단

① 모수에 대한 검정



모형 조건 만족 여부

정상성&가역성

: 모수의 절댓값이 1보다 작음

식별성

: 모수의 합이 0이 아님



모수의 유효성 여부

: 모수의 값이 0이 아님

정상 시계열 모형의 적합 절차 | 모형 진단

② 잔차에 대한 검정



추세/계절성/이상치 존재 여부



정규성 만족 여부

검정방법

잔차의 QQ' plot

Jarque-Bera test



자기상관성 유무 : WN $(0, \sigma^2)$ 를 따르는지

검정방법

잔차에 대한 ACF/PACF plot

Ljung-Box test

McLeod-Li test

Different sign test

정상 시계열 모형의 적합 절차 | 예측



실제로 사용 빈도가 높은 finite 방법에 대해 알아볼 예정

정상 시계열 모형의 적합 절차 | 예측

$$P_n X_{n+h} = a_0 * 1 + a_1 X_n + a_2 X_{n-1} + \dots + a_n X_1$$

n개의 자료를 이용해 n+h 시점을 예측했음을 의미 즉, 가지고 있는 데이터의 선형결합을 활용해 미래를 예측하는 방법

finite 방법

정상 시계열 모형의 적합 절차 | 예측

$$P_n X_{n+h} = a_0 * 1 + a_1 X_n + a_2 X_{n-1} + \dots + a_n X_1$$

계수 추정 방법

MSPE(Mean Squared Prediction Error)를 최소화하는 방향으로 추정

$$MSPE = \mathbb{E}[X_{n+h} - P_n X_{n+h}]^2$$

= $\mathbb{E}[X_{n+h} - (a_0 * 1 + a_1 X_n + a_2 X_{n-1} + \dots + a_n X_1)]^2$

정상 시계열 모형의 적합 절차 | 예측

계산방식

LSE와 동일!

각 계수 $\{a_0, a_1, ..., a_n\}$ 에 대한 편미분식 값을 0으로 두고,

각 normal equation을 연립하여 해 도출



계수 추정 방법

MSPE(Mean Squared Prediction Error)를 최소화하는 방향으로 추정

$$MSPE = \mathbb{E}[X_{n+h} - P_n X_{n+h}]^2$$

= $\mathbb{E}[X_{n+h} - (a_0 * 1 + a_1 X_n + a_2 X_{n-1} + \dots + a_n X_1)]^2$

4

비정상 시계열 모형

ARIMA: 자기회귀누적이동평균모형

ARIMA 모형

d차 차분 후 $Y_t = (1 - B)^d Z_t$ 가 ARMA(p,q)를 따르는 모형





차분과 ARMA가 결합된 형태



차분을 통해 추세를 제거

ARIMA: 자기회귀누적이동평균모형

ARIMA 모형

d차 차분 후 $Y_t = (1 - B)^d Z_t$ 가 ARMA(p,q)를 따르는 모형

주어진 시계열 데이터가 polynomial trend를 가지고 있고, 그 오차가 ARMA(p,q)를 따를 때 사용하는 모델

ARIMA: 자기회귀누적이동평균5형

ARIMA 도차분과 ARMA를 결합한 모형을 ARDMA가

d차 차분 후아니라 ARIMA로 정의한 일유로는 모형


$$\phi(B)(1-B)^{d}X_{t} = \theta(B)Z_{t}$$

$$X_{t} = X_{t-1} + Y_{t} = (X_{t-2} - Y_{t-1}) + Y_{t} = \dots = X_{0} + \sum_{j=1}^{t} Y_{j}$$

주어진 시계열 데이터가 polynomial trend를 가지고 있고, X_t 와 Y_t 의 누적(Integration)합으로 볼 수 있으며, $\frac{2}{1000} \frac{1}{1000} \frac{1}{10000} \frac{1}{1000} \frac{1}{10000} \frac{1}{1000} \frac{$

ARIMA | 모델 적합 절차

① 정상 / 비정상 시계열 판단






시계열 plot과 ACF 그래프를 통해 정상 시계열인지 비정상 시계열인지 판단

ARIMA | 모델 적합 절차

① 정상 / 비정상 시계열 판단



정상시계열은 ACF가 지수적으로 감소하지만,

비정상 시계열을 ACF가 <mark>천천히</mark> 감소하는 것을 통해 적절한 모형 선택

ARIMA | 모델 적합 절차

② 정상화

추세가 존재하는 비정상 시계열 데이터에 1차 또는 2차 차분 진행

d차 차분이 아닌 1,2차 차분을 적용하는 이유?

d차 차분 시 필요 이상으로 차분 되는 <mark>과대차분</mark> 발생 가능성 존재 (ACF가 복잡해지거나 분산이 커지는 등의 문제 발생 可)



과대차분을 방지하기 위해 1, 2차 차분 사용

ARIMA | 모델 적합 절차

② 정상화

추세가 존재하는 비정상 시계열 데이터에 1차 또는 2차 차분 진행


d차 차분이 아닌 1,2차차분을 적용하는 이유?

ACF와 PACF 그래프가 지수적으로 감소하면 적절한 정상화

과대차분을 방지하기 위해 1, 2차 차분 사용

ARIMA | 모델 적합 절차

③ p, q 차수 결정



모형 적합 절차에 따라 p,q의 차수를 결정하고,

모수를 추정하고 진단까지 마친 모형을 통해 예측 진행

ARIMA | 모델 적합 절차



③ p, q 차수 결정

Forecasts from ARIMA(3,1,1)

정상화에서 계절성은 결정적 계절성으로

모든 주기에서 계절성이 동일함을 가정

그러나, 실증 데이터에서는 결정적이지 않을 수 있음

9

주기에 따라 계절성도 변함을 반영하는 SARIMA 모형을 사용

모수를 추정하고 진단까지 마친 모형을 통해 예측 진행

SARIMA: Seasonal ARIMA

SARIMA 모형

추세와 계절성이 모두 존재하는 비정상 데이터에 적용하는 모형

가장 확장된 형태의 ARMA모형으로, 계절성 사이의 상관관계에 대해 모델링하는 확률적 접근법

	11			
	month 1	month 2		month 12
Year 1	$-Y_1$	Y_2		Y ₁₂
Year 2	Y ₁₃	Y ₁₄		Y ₂₄
:	1 1	i	:	ŧ
Yearr	$Y_{1+12(r-1)}$	$Y_{2+12(r-1)}$		$Y_{12+12(r-1)}$
	_\			

▲ ARMA(P,Q)를 따른다고 가정 → 계절성 모델링

$$Y_{j+12t} - \Phi_1 Y_{j+12(t-1)} - \dots - \Phi_P Y_{j+12(t-P)}$$

$$= U_{j+12t} + \Theta_1 U_{j+12(t-1)} + \dots + \Theta_Q U_{j+12(t-Q)}$$

$$(where \ t = 0,1,\dots,r, \quad U_t \sim WN(0,\sigma_U^2))$$

$$\Phi(B^{12})Y_t = \Theta(B^{12})U_t$$

	month 1	month 2		month 12
Year 1	$-Y_1$	<i>Y</i> ₂		Y ₁₂
Year 2	Y ₁₃	Y_{14}		Y ₂₄
÷		:	:	i
Year r	$Y_{1+12(r-1)}$	$Y_{2+12(r-1)}$		$Y_{12+12(r-1)}$

ARMA(P,Q)를 따른다고 가정 > 계절성 모델링

$$Y_{j+12t} - \Phi_1 Y_{j+12(t-1)} - \dots - \Phi_P Y_{j+12(t-P)}$$

Month가 달라져도 파라미터는 같음

$$\Phi(B^{12})Y_t = \Theta(B^{12})U_t$$

	month 1	month 2		month 12
Year 1	Y_1	Y_2		Y ₁₂
Year 2	Y ₁₃	Y_{14}		Y ₂₄
i	<u>:</u> !	: L	::	<u> </u>
Year r	$Y_{1+12(r-1)}$	$Y_{2+12(r-1)}$		$Y_{12+12(r-1)}$



서로 다른 Month 간 correlation이 있을 수 있음 한 주기 내에서의 의존성: ARMA(p,q)로 모델링

$$\phi(B)U_t = \theta(B)Z_t, Z_t \sim WN(0, \sigma^2)$$

	month 1	month 2	•••	month 12
Year 1	Y ₁	Y_2		Y ₁₂
Year 2	Y ₁₃	Y ₁₄		Y ₂₄
i i	÷	:	:	:
Yearr	$Y_{1+12(r-1)}$	$Y_{2+12(r-1)}$		$Y_{12+12(r-1)}$

추세 존재 시 d차 차분을 통해 차분 모델링

$$Y_t = (1 - B)^d (1 - B^{12}) X_t$$

세 과정을 합쳐 SARIMA(p,d,q)x(P,D,Q)를 완성할 수 있음

 $\phi(B)\Phi B^{12}\left((1-B)^d\ (1-B^{12})^D\right)X_t = \theta(B)\Theta(B^{12})Z_t, Z_t \sim WN(0,\sigma^2)$

순수 SARIMA

순수 SARIMA

계절성만을 고려하는 모델로 주기에 대한 차수인 (P,D,Q)s만 있고 전체 시계열에 대한 차수인 (p,d,q)는 없는 모형

$$\Phi(B^s)(1 - B^s)^D X_t = \Theta(B^s) Z_t$$


$$\Phi(B^s) = (1 - \Phi_1 B^s - \Phi_2 B^{2s} - \dots - \Phi_P B^{Ps})$$

$$\Theta(B^s) = (1 + \Theta_1 B^s + \Theta_2 B^{2s} + \dots + \Theta_Q B^{Qs})$$

$$Z_t \sim WN(0, \sigma^2)$$

비정상 시계열 모형

순수 SARIMA




ACF/PACF가 주기 s에서 유효한 값, 다른 시차에서는 0



모든 시차의 ACF/PACF 값을 보는 것이 아닌 주기의 배수를 관측해야 함

순수 SARIMA




그 외의 패턴은 ARMA와 동일 SACF는 감소, SPACF는 첫 번째 주기 이후 절단 →SAR(1,0,0) 모형임을 알 수 있음



순수 SARIMA







순수 SARIMA 모형은 비계절 요소에 대한 부분은



비계절 요소를 고려하는 승법 SARIMA 모형을 사용

SACF는 감소, SPACF는 첫 번째 주기 이후 절단

→SAR(1,0,0) 보형임을 알 수 있음

4 비정상 시계열 모형

승법 SARIMA


승법 SARIMA

오차가 ARMA를 따름을 가정하여

계절 이외의 요소의 연관성도 고려하는 모형

모수 절약의 원칙에 따라 순수 SARIMA보다 더 자주 사용됨


승법 SARIMA



비계절성 요소의 경우 한 주기 내의 ACF와 PACF의 패턴을 통해 파악 계절적 요소의 경우는 순수 SARIMA와 동일함(주기의 배수를 관측)

승법 SARIMA





비계절성 요소의 경우 **한 주기 내**의 ACF와 PACF의 패턴을 통해 파악 계절적 요소의 경우는 순수 SARIMA와 동일함(주기의 배수를 관측)

5

이분산 시계열 모형

변동성 집중(Volatility Clustering)

전통적 시계열 모형

분산에 변화가 없음을 가정 후, 평균의 움직임에만 관심을 가짐



AR(1) 모형의 조건부 평균과 분산은 시간에 따라 일정함을 가정

$$Y_{t} = \phi_{1}Y_{t-1} + \varepsilon_{t}, \, \varepsilon_{t} \sim WN(0, \sigma^{2})$$

$$E[Y_{t}|Y_{t-1}] = \phi_{1}Y_{t-1}, Var(Y_{t}|Y_{t-1}) = \sigma^{2}$$

변동성 집중(Volatility Clustering)



분산에 변화가 없음을 가전 후 평균의 움직임에만 과식을 가짐 수익률, 추가, 환율 등 금융 관련 시계열 자료는

분산이 과거에 의존하는 <mark>시간에 따른 이분산성</mark>을 가짐

AR(1) 모형의 조건부 평균과 분산은

시간에 따라 변화하는 분산을 다루기 위한

새로운 시계열 프레임 워크가 필요함! $Y_t = \phi_1 Y_{t-1} + \varepsilon_t, \, \varepsilon_t \sim WN(0, \sigma^2)$

 $E[Y_t|Y_{t-1}] = \phi_1 Y_{t-1}, Var(Y_t|Y_{t-1}) = \sigma^2$

변동성 집중(Volatility Clustering)

이분산성 Heteroscedasticity

분산이 시간이나 관측치별로

독립적으로 나타나지 않거나 일정하지 않음을 의미

Г-----! !

비조건부 이분산성

조건부 이분산성


일반적인 구조적 변동성의 변화가 이전 기간의 변동성과 관련이 없을 때 일정하지 않은 변동성이 이전 시점의 변동성과 연관이 있을 때

변동성 집중(Volatility Clustering)

이분산성 Heteroscedasticity

분산이 시간이나 관측치별로


독립적으로 나타나지 않거나 일정하지 않음을 의미



변동성 집중(Volatility Clustering)

변동성 집중 Volatility Clustering

큰 변화가 당분간 계속 큰 변화를 유지하며, 작은 변화는 당분간 작은 변화를 유지하는 경향




√ , log transformation으로 상쇄시킬 수 없음
→ 오차의 제곱에 대한 시계열 모형 적용

ARCH: 자기회귀이분산모형

Ex.

영화관 매표 판매량 예측 모델을 적합 시킨 뒤의 오차항



변동성 집중이 발생하므로 이에 대한 모델링 필요

ARCH: 자기회귀이분산모형

Ex.

영화관 매표 판매량 예측 모델을 적합 시킨 뒤의 오차항



변동성을 과거 시점의 분산으로 설명
$$Var(\varepsilon_t) = \sigma_t^2 = \alpha_0 + \alpha_1 \sigma_{t-1}^2$$



과거 오차가 컸다면 미래 오차도 커짐을 가정 $\varepsilon_t = w_t \sqrt{\alpha_0 + \alpha_1 \varepsilon_{t-1}^2}, \ w_t \sim WN(0,1)$



양변을 제곱하여 AR type 함수로 오차항 설명 $\varepsilon_t^2 = w_t^2 (\alpha_0 + \alpha_1 \varepsilon_{t-1}^2)$

ARCH: 자기회귀이분산모형

자기회귀이분산모형 ARCH

오차의 변동성이 자기회귀적으로 변하는 것을 설명하는 비선형 모델

$$\begin{split} Z_t \sim & \operatorname{N}(0,1), \varepsilon_t = \sigma_t Z_t \\ \sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 \\ = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2 + \dots + \alpha_p \varepsilon_{t-p}^2 \\ \alpha_0 > 0, \alpha_j \geq 0, j = 1, 2, \dots, p \end{split}$$

ARCH(P)모형은 t 시점 오차항의 변동성을 P 시점 전까지의 오차항의 제곱으로 설명



과거의 오차항으로 변동성 설명 가능

ARCH: 자기회귀이분산모형



ARCH 모형의 한계

자기회귀이분산모형 ARCH

오차의 변동성이 자귀회귀적으로 변하는 것을 설명하는 비선형 모델

과거 오차의 제곱을 이용하여 <mark>방향(+/-)에 따른 영향력</mark>을 반영하지 못하고

-- P 값이 커지면 추정해<u>야할 모수가 많아지고 추정량의 정확도 하락</u>

$$Z_t \sim N(0,1), \varepsilon_t = \sigma_t Z_t$$

ARCH(P)모형은 t 시점 오차항의 변동성을

P 시점 전까지의 오차항의 제곱으로 설명

$$\sigma_{t}^{2} = \alpha_{0} + \sum_{i=1}^{p} \alpha_{i} \varepsilon_{t-i}^{2}$$

 $= \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2$ 보다 일반화된 로모델 GARCH의 필요성!

$$\alpha_0 > 0, \alpha_j \ge 0, j = 1, 2, \dots, p$$

과거의 오차항으로 변동성 설명 가능

GARCH: 일반자기회귀이분산모형

일반자기회귀이분산모형 GARCH

오차의 변동성이 자기회귀적으로 변하는 것을 설명하는 비선형 모델


$$\begin{split} Z_t \sim & \mathrm{N}(0,1), \varepsilon_t = \sigma_t Z_t \\ \sigma_t^2 = \alpha_0 + \sum\nolimits_{\mathrm{i}=1}^{\mathrm{p}} \alpha_{\mathrm{i}} \varepsilon_{\mathrm{t-i}}^2 + \sum\nolimits_{j=1}^{q} \beta_{j} \sigma_{\mathrm{t-j}}^2 \\ = \alpha_0 + \alpha_1 \varepsilon_{\mathrm{t-1}}^2 + \alpha_2 \varepsilon_{\mathrm{t-2}}^2 + \dots + \alpha_{\mathrm{p}} \varepsilon_{\mathrm{t-p}}^2 + \beta_1 \sigma_{\mathrm{t-1}}^2 + \beta_2 \sigma_{\mathrm{t-2}}^2 + \dots + \beta_{\mathrm{p}} \sigma_{\mathrm{t-q}}^2 \\ \alpha_0 > 0, \alpha_{\mathrm{j}} \geq 0, \beta_{\mathrm{j}} \geq 0 \end{split}$$

GARCH: 일반자기회귀이분산모형

일반자기회귀이분산모형 GARCH

오차의 변동성이 자기회귀적으로 변하는 것을 설명하는 비선형 모델

GARCH(p,q)모형은 $Z_t \sim N(0,1), \varepsilon_t = \sigma_t Z_t$ t 시점 오차항의 변동성을 p 시점 이전의 오차항 제곱과 $t = \alpha_1 \varepsilon_{t-1}^2 + \sum_{i=1}^p \alpha_i \varepsilon_{t-1}^2 + \sum_{i=1}^q \alpha_i \varepsilon_{$




6

2주차 정리

6 2주차 정리

정리 | 시계열 모형의 필요성



모델 추정 프로세스 종료

오차를 추정하는 모델링 진행

정리 | AR & MA

AR: 자기회귀모형

$$AR(1): \phi_{1}X_{t-1} + Z_{t}$$

$$AR(p): X_{t} = \phi_{1}X_{t-1} + \phi_{2}X_{t-2} + \dots + \phi_{p}X_{t-p} + Z_{t}$$

$$where Z_{t} \sim WN(0, \sigma^{2})$$

MA: 이동평균모형

$$MA(1): X_t = Z_t + \theta_1 Z_{t-1}$$

$$MA(q): X_t = Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \dots + \theta_q Z_{t-q}$$

$$where Z_t \sim WN(0, \sigma^2)$$

6 2주차 정리

정리 | AR & MA 비교

	ACF	PACF
AR(p)	지수적으로 감소	p이후 절단
MA(q)	q이후 절단	지수적으로 감소



ACF와 PACF를 관찰하여 적절한 모형을 선택할 수 있음

정리 | ARMA & ARIMA & SARIMA

ARMA: AR+MA

$$\phi(B)X_t = \theta(B)Z_t$$

ARIMA: ARMA + 차분

$$\phi(B)(1-B)^{d}X_{t} = \theta(B)Z_{t}$$

SARIMA: ARIMA + 계절성

$$\phi(B)\Phi(B^s)(1-B)^{\mathrm{d}}(1-B^s)^D X_t = \theta(B)\Theta(B^s)Z_t$$


6 2주차 정리

정리 | ARCH & GARCH

이분산성 Heteroscedasticity

분산이 시간이나 관측치별로

독립적으로 나타나지 않거나 일정하지 않음을 의미



조건부 분산을 과거 시점의 오차항으로 설명

$$\varepsilon_t = \sigma_t Z_t$$
, $\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2$

분산에 ARMA 모형을 가정하여 ARCH를 확장한 모델

$$\sigma_{t}^{2} = \alpha_{0} + \sum_{i=1}^{p} \alpha_{i} \varepsilon_{t-i}^{2} + \sum_{j=1}^{q} \beta_{j} \sigma_{t-j}^{2}$$

다음 주 예고

- 1. 시계열 데이터의 전처리
 - 2. 혼합형 시계열 모형
 - 3. 시계열과 머신러닝
 - 4. 시계열과 딥러닝

시결 엠티가서 고백 받음







마니또걸즈

시계열 in 하얀집

강철석, 이승아 닌자설















신영이 자니…